

Informe Técnico: Análisis de Mantenimiento Predictivo y Detección de Anomalías

Este informe presenta un análisis completo de mantenimiento predictivo utilizando técnicas de Machine Learning y Detección de Anomalías. Se generaron datos simulados temporales para múltiples equipos a lo largo de 40 tiempos para predecir fallos y detectar anomalías en su evolución. Se entrenaron múltiples modelos y se evaluaron sus desempeños mediante métricas estándar y visualizaciones detalladas.

1. Análisis Exploratorio de Datos (EDA)

Figura 1: Distribución de Fallos vs No Fallos




Figura 2: Matriz de Correlación de Datos Simulados




Figura 3: Histogramas de Variables

Histograms of Variables




Figura 4: Boxplots de Variables





Figura 5: Pairplot de Variables



2. Detección de Anomalías

Se aplicaron cinco algoritmos diferentes de detección de anomalías para identificar comportamientos inusuales en los datos temporales.

Figura 6: Detección de Anomalías - IsolationForest




Figura 7: Detección de Anomalías - OneClassSVM




Figura 8: Detección de Anomalías - LocalOutlierFactor




Figura 9: Detección de Anomalías - DBSCAN





Figura 10: Detección de Anomalías - PCA_Outlier




3. Evaluación de Modelos de Clasificación

3.1 *RandomForest*

ROC AUC: 0.9694

PR AUC: 0.9690

Figura 11: Matriz de Confusión - RandomForest




3.2 *SVM*

ROC AUC: 0.9683

PR AUC: 0.9683

Figura 12: Matriz de Confusión - SVM




3.3 GradientBoosting

ROC AUC: 0.9679

PR AUC: 0.9672

Figura 13: Matriz de Confusión - GradientBoosting



3.4 LogisticRegression

ROC AUC: 0.9670

PR AUC: 0.9668

Figura 14: Matriz de Confusión - LogisticRegression





Figura 11: Curvas ROC y Precision-Recall



4. Importancia de Características

Figura 13: Importancia de Características - RandomForest





Figura 15: Importancia de Características - GradientBoosting



5. Conclusiones

Los modelos de clasificación evaluados demostraron un desempeño prometedor en la predicción de fallos de equipos. Entre los modelos evaluados, Random Forest y Gradient Boosting presentaron las mejores métricas de rendimiento, indicando una alta capacidad para distinguir entre equipos que fallarán y los que no. La detección de anomalías mediante cinco diferentes algoritmos permitió identificar comportamientos inusuales en la evolución temporal de los equipos. Las variables como la vibración, la calidad del aceite, las horas operadas, y el historial de mantenimiento fueron las más determinantes para predecir fallos. Estos hallazgos sugieren que un monitoreo continuo y un mantenimiento preventivo basado en estas métricas pueden mejorar significativamente la fiabilidad de los equipos.